مشروع خط أنابيب تجميع وتحليل بيانات التجارة الإلكترونية

E-Commerce Data Integration & Analytics Pipeline - Project Documentation

1. الخطة الزمنية لتنفيذ المشروع (Project Timeline)

تم تقسيم العمل على مدار 5 أسابيع متتالية لضمان التطوير المنهجي، بدءاً من تحليل المتطلبات وحتى التسليم النهائي والأتمتة الكاملة.

الأسبوع الأول: التخطيط وتحديد المتطلبات

جمع وتحديد المتطلبات الوظيفية وغير الوظيفية، تحديد مصادر البيانات (APIs, CSV)، وإعداد البيئة البرمجية وحاويات Docker.

الأسبوع الثاني: الاستخراج والتصميم

بناء وحدات استخراج البيانات من الـ REST API والملفات، وتصميم نموذج قاعدة البيانات العلائقية (Star Schema).

الأسبوع الثالث: المعالجة والتنظيف

تطبيق عمليات المعالجة باستخدام Pandas، تنظيف البيانات من التكرارات والقيم المفقودة، وتطبيق قواعد جودة البيانات.

الأسبوع الرابع والخامس: الأتمتة والتسليم

بناء خطوط العمليات بواسطة Apache Airflow، إضافة معالجة الأخطاء والـ Logging، إعداد التوثيق النهائي ورفع المشروع على GitHub.

2. توزيع المهام والمسؤوليات على أعضاء الفريق

تم توزيع الأدوار بناءً على المكونات الرئيسة للهندسة البرمجية للمشروع لضمان التوازى والتكامل بين كافة الأعضاء:

الاسم	الكود	الدور الموكل	المسؤوليات الأساسية
أحمد سيف محمد سيف	21120168	**API Extractor**	استخراج بيانات المنتجات من الـ REST API وتطوير وحدة الاتصال ومعالجة أخطاء الشبكة.
ساره اشرف مجاهد جوده	21126250	**Files Ingestion**	قراءة بيانات العملاء والطلبات من CSV/JSON والتحقق من المخطط الهيكلي للبيانات الخام.
زياد محمد علي الحاج	21157957	**ETL Developer**	معالجة وتنظيف البيانات بواسطة Pandas، معالجة القيم المفقودة وإزالة التكرارات والتنسيق.
محمد بهاء عبدالرحمن عبدالعظيم	21143765	**Data Modeling**	تصميم الـ Star Schema وتأسيس قاعدة البيانات وكتابة استعلامات SQL والـ Views التحليلية.
محمد عبدالرءوف محمود الجنزوري	21027940	**Orchestration**	إدارة وبناء Airflow DAGs، متابعة جودة البيانات، إعداد التوثيق الشامل ورسم Architecture Diagram.

3. إدارة المخاطر المحتملة وطرق التعامل معها (Risk Management)

لضمان استقرار خط أنابيب البيانات واستمراريته دون انقطاع، تم الاستعداد للمخاطر التقنية التالية:

نوع الخطر	الوصف / التأثير	خطة المواجهة والحد من الأثر (Mitigation Strategy)
توقف الـ API أو التأخر	تعطل عملية جلب البيانات اليومية للمنتجات.	تطبيق Retry Logic بفاصل زمني تصاعدي، واستخدام Caching للبيانات الأخيرة.
تغير هيكل البيانات (Schema Change)	فشل عملية التحميل والتنظيف بسبب تغير أعمدة Input.	تطبيق وحدة فحص المخطط (Schema Validation Check) قبل مرحلة التمرير لرفع التنبيهات.
تكرار أو تلوث البيانات	تأثير سلبي على دقة تقارير المبيعات التحليلية.	تطبيق مفاتيح فريدة (Unique Constraints) وتأكيد عمليات Deduplication عبر Pandas.
فشل مهام Airflow	عدم اكتمال الـ Pipeline في الموعد المحدد.	إعداد Alerting عبر البريد الإلكتروني وسجلات Logging تفصيلية للتعرف السريع على الأخطاء.

4. مؤشرات قياس نجاح المشروع (Success KPIs)

يتم تقييم مدى نجاح المشروع بناءً على المخرجات التقنية والتشغيلية التالية:

- **معدل اكتمال البيانات (Data Completeness Rate):** تحقيق نسبة ≤ 99% في اكتمال البيانات الخالية من القيم المفقودة والتكرارات.
- **استقرار خط الأنابيب (Pipeline Reliability):** تشغيل أوتوماتيكي بنجاح دون أخطاء حرجة بنسبة 95%+ على Apache Airflow.
- **زمن المعالجة (Pipeline Execution Time):** إتمام الدورة الكاملة لـ (Extract -> Load) في زمن لا يتعدى بضع دقائق.
- **كفاءة الاستعلامات (Query Latency):** سرعة استجابة الـ SQL Views التحليلية بفضل الفهارس والـ Star Schema.
- **جودة التوثيق (Documentation & Code Standard):** وجود مستندات README شاملة واختبارات متكاملة ورسم معماري دقيق.

5. دراسة المشاريع المشابهة (Literature Review)

تمت دراسة العديد من الحلول والأنظمة البرمجية المتاحة في السوق للتعرف على نقاط القوة والضعف ومقارنتها بنظامنا المستهدف:

المشروع / الحل المقارن	المميزات	العيوب	وجه المقارنة مع مشروعنا
Stitch / Fivetran	ربط سريع وسهل لأغلب المصادر الجاهزة.	تكلفة عالية جداً وتخصيص محدود للمجانية.	مشروعنا يوفر مرونة كاملة بكود مفتوح المصدر بدون تكاليف.
Custom Python Cron Scripts	بسيط في التنفيذ ولا يحتاج بنية معقدة.	غياب نظام مراقبة المهام وإعادة التشغيل عند الفشل.	مشروعنا يعتمد على Airflow للجدولة الذكية والمراقبة الحية.
Traditional ETL Tools (SSIS)	واجهات بيانية سهلة ونظم قديمة متماسكة.	صعبة التكامل مع الأنظمة الحديثة وغير مرنة برمجياً.	مشروعنا حديث يعتمد على Python, SQL, Cloud-ready architecture.

المصادر المستخدمة: Apache Airflow Documentation, Kimbal Methodology for Data Warehousing, Microsoft Azure Data Architecture Guides.

6. تحديد المتطلبات (Requirements Gathering)

الأطراف المستفيدة (Stakeholders) واحتياجاتهم:

- **محللو البيانات (Data Analysts):** يحتاجون لبيانات موحدة ومنظمة وسريعة للاستعلام للحصول على تقارير المبيعات.
- **مديرو المبيعات (Sales Managers):** يحتاجون لرؤية شاملة حول أداء المنتجات وسلوك العملاء لاتخاذ القرارات.
- **مهندسو البيانات (Data Engineers):** يحتاجون لنظام مستقر وسهل الصيانات وموثق بشكل كامل.

الوظائف ومتطلبات الجودة (Functional & Non-Functional Requirements):

- **المتطلبات الوظيفية (Functional):** استخراج البيانات تلقائياً، تنظيفها، حفظها في Star Schema، وإنشاء Views.
- **الأداء (Performance):** معالجة آلاف السجلات خلال ثوانٍ معدودة دون الضغط على قواعد البيانات العملية.
- **الأمان (Security):** تشفير بيانات الاتصال والحفاظ على السرية وحماية بيانات العملاء الشخصية.
- **سهولة الاستخدام والتكامل:** كود نظيف مقسم لوحدات (Modular)، وسهل التشغيل باستخدام حاويات Docker.